

M-Engine 原理说明书

目录

- [一句话定义](#)
- [从一个问题开始](#)
- [核心隐喻：记忆的傅里叶变换](#)
- [三层架构](#)
- [第一层：记忆的压缩与存储](#)
- [第二层：理解的重构与调制](#)
- [第三层：认知的自发演化](#)
- [完整交互循环](#)
- [统一方程](#)
- [价值论证](#)
- [与现有系统的区别](#)
- [局限性](#)

一句话定义

M-Engine 是一个**独立于 LLM 的、可自演化的认知记忆层**。它不存储原始文本，而是将事实压缩为在"世界基本逻辑维度"上的频谱系数；不同的问题和偏好从同一频谱中提取不同的骨架，重构出不同的回答；基函数本身在博弈中竞争、合作、繁殖、死亡。

从一个问题开始

你告诉 ChatGPT "我叫小明，我是素食者"。它记住了。但它是怎么记住的？

答案是：不知道。模型的"记忆"分布在数十亿个权重参数中，没有人能指出"小明是素食者"这个事实存储在哪个位置、以什么形式存在。

更关键的是——你下次问"What should I cook for Xiao Ming?"，模型确实会给出素食方案。但它不是在"回忆"你告诉它的事实，而是在推理时，你的上下文+训练数据中的统计模式共同产生了这个输出。这不是"记忆-检索-回答"，而是"模式补全"。

M-Engine 回答同一个问题的路线完全不同。它不是靠统计模式，而是靠一个可解释的、结构化的认知过程——并且你可以看到它每一步都在做什么。

核心隐喻：记忆的傅里叶变换

标准傅里叶变换

任意一段音频波形，可以分解为若干不同频率的正弦波的叠加：

$$\text{原始信号} = A_1 \cdot \sin(\omega_1 t) + A_2 \cdot \sin(\omega_2 t) + A_3 \cdot \sin(\omega_3 t) + \dots$$

系数 $A_1, A_2, A_3, \dots$ 就是信号的**频谱**。它不保留原始波形的每一个采样点，但保留了"骨架"——主要频率成分及其强度。从频谱可以重建出与原始信号非常相似的波形。

M-Engine 的类比

把"正弦波"替换为"世界基本逻辑维度"——比如因果关系、时间顺序、情感色调、角色动机、道德判断等等。这些就是**基函数**。

一段事实（比如"小明因为考试不及格哭了"）不再作为原始文本存储，而是被分解为在这些基函数上的投影系数：

$$\text{事实"小明哭了"} = 0.7 \cdot \text{因果关系} + 0.1 \cdot \text{时间顺序} + 0.6 \cdot \text{情感色调} + 0.3 \cdot \text{角色动机} + \dots$$

这个系数向量就是该事实的**频谱**——它在每个认知维度上的"能量强度"。

为什么这个类比有用

在标准傅里叶变换中，**不同频率的滤波**可以从同一个频谱中提取不同的信号成分（高通滤波得到高频细节，低通滤波得到低频轮廓）。

在 M-Engine 中，**不同问题的滤波权重**从同一个事实频谱中激活不同的认知维度：

- 问题"为什么" → 因果关系权重高，情感权重低 → 激活因果维度的频谱成分 → 回答侧重因果链
- 问题"感受如何" → 情感权重高，因果权重低 → 激活情感维度的频谱成分 → 回答侧重心理体验

同一份记忆，不同的问题得到不同的回答。这与人类的记忆行为一致——我们不会在每次回忆时"播放"完全相同的内容，而是根据当前的问题和心境，从同一个记忆中提取不同的侧面。

三层架构

M-Engine 不是扁平的"检索+生成"。它有三层递进结构：

第三层：认知演化层	
基函数种群在博弈中竞争、合作、繁殖、死亡	
安全约束作为适应度惩罚项注入	
第二层：理解层	
问题路由：自然语言 → 基函数滤波权重	
偏好调制：用户/模型增益叠加	
频谱重构：频谱 · 滤波权重 → 激活向量 → 回答	
第一层：存储层	
事实 → 基函数频谱压缩	
嵌入向量 → 语义检索	
SQLite 持久化	

第一层：记忆的压缩与存储

基函数定义

系统启动时加载 10 个预定义基函数（可随演化增减）：

基函数	含义	示例问题
因果关系	事件之间的因果链	"为什么会发生？"
时间顺序	事件的前后、持续、节奏	"什么时候发生的？"
情感色调	事件中的情感色彩	"他是什么感受？"
角色动机	行为背后的驱动力	"他为什么这么做？"
空间关系	位置、距离、环境	"发生在哪里？"
逻辑一致性	叙述是否自洽	"有没有矛盾？"
意图推测	未明说的意图	"他到底想怎样？"
社会关系	人际纽带与权力	"他们什么关系？"
对比差异	事物间的反差	"和之前有什么不同？"
道德判断	善恶对错的评价	"这样做对吗？"

频谱初始化

当一段文本被作为事实存入系统时，它在每个基函数上的频谱值被初始化为均匀的小值（0.1）。这代表系统对它还没有具体的"理解"——所有维度一视同仁。

```
fact.spectrum = {  
  "basis_causality": 0.1,  
  "basis_emotion": 0.1,  
  "basis_motivation": 0.1,  
  # ... 所有10个维度都是0.1  
}
```

同时，文本通过嵌入模型（如 DeepSeek API 或本地 Ollama）生成一个向量，用于语义检索。

存储效率

一个事实的存储成本 = 10个浮点数（频谱）+ 1个嵌入向量（768维）= 约3KB。原始文本可能数十字到数千字。这是约 10-100 倍的压缩比。代价是损失了"血肉细节"——系统只记住这个事实在每个认知维度上的"骨架强度"，无法还原原文。

第二层：理解的重构与调制

这是系统的核心计算层。一次提问经历以下步骤：

步骤 1：问题路由

用户问"小明为什么哭了？"系统不是用关键词匹配"为什么"→"因果关系"，而是将问题嵌入到一个高维向量中，与每个基函数的**策略向量**（strategy vector）计算对齐度。每个基函数都是一个博弈玩家，它在基函数空间中占据一个位置，问题落在哪个方向，哪个基函数就被激活。

```
激活强度[i] = softmax( query_embedding · strategy_vector[i] )
```

步骤 2：偏好调制

不同用户对同一个问题有不同的"认知偏向"。偏好通过**增益向量**表达——增益 > 1.0 表示该用户对该维度更敏感。

$$\text{最终激活} = \text{基础激活} \odot \text{用户增益} \odot \text{模型增益}$$

例如：

- 逻辑型用户：因果关系增益 2.0，情感增益 0.5 → 回答侧重因果链
- 共情型用户：情感增益 3.0，因果增益 0.3 → 回答侧重内心体验

同一个问题，不修改任何事实数据，只切换增益参数，就得到不同的回答。

步骤 3：频谱重构

检索到的事实，其频谱向量与步骤 2 中产生的滤波权重做逐元素乘积：

$$\text{激活向量} = \text{平均频谱} \odot \text{滤波权重}$$

这个激活向量中的每个分量代表"在当前问题和偏好的视角下，该认知维度被激活的强度"。

步骤 4：结构化提示生成

系统构造一个结构化 prompt，列出激活最高的几个维度及其强度，附上相关事实，然后调用 LLM（如 DeepSeek）生成最终回答。

【当前激活的认知维度】

■■■■■ 因果关系（强度：0.312）

■■■■■ 角色动机（强度：0.188）

■■■■ 情感色调（强度：0.078）

【相关事实】

事实 1：小明因为数学考试不及格，被爸爸严厉批评后，在房间里哭了整整一个下午。

请从上述激活维度出发，综合分析后回答问题。

步骤 5：反馈学习

用户对回答给予反馈（-1.0 到 1.0）。系统通过**复制者动态方程**更新事实频谱：

$$\text{新频谱}[i] = \text{旧频谱}[i] + \text{学习率} \times \text{激活强度}[i] \times (\text{收益}[i] - \text{平均收益})$$

正反馈 → 参与回答的基函数在该事实上获得更多频谱权重 → 下次类似问题更突出这些维度。

负反馈 → 削弱。

这不是"缓存正确答案"，而是"调整理解方式"。

第三层：认知的自发演化

前面两层已经是完整的记忆系统。第三层让它从"工具"变成"活系统"。

基函数作为博弈玩家

每个基函数现在是一个**策略个体**（StrategyAgent），有：

- 策略向量**：它在基函数空间中的"位置"，决定它对哪些问题敏感
- 能量**：累计适应度，相当于"这个维度有多有用"
- 安全风险**：由监控层评估
- 交互网络**：与其他基函数的协同/竞争关系

三层嵌套博弈

层级	内容	时间尺度	适应度定义
微观	每次问答中基函数的频谱竞争	秒~分钟	重构贡献 + 探索奖励 - 安全惩罚
中观	基函数种群的策略竞争与生态位分化	小时~天	长期平均能量 + 多样性
宏观	系统安全、价值对齐	周~月	危险共振指数、认知闭环检测

四大演化操作

死亡：能量长期低于阈值的基函数被淘汰。保护初代基函数（系统自带的 10 个起步维度）。

合并：两个基函数的策略向量和激活模式高度相似时，合并为一个，消除冗余。

分裂：一个基函数的激活方差过高（有时极强、有时极弱）时，拆分为两个更细粒度的子维度。

新生：当事实空间中存在大量未被任何基函数覆盖的"认知缺口"时，从现有策略的变异中产生新基函数。

在 DeepSeek 测试中，系统自发生成了新基函数"社会关系+因果关系"——它是"社会关系"和"因果关系"两个亲本的交叉繁殖产物。

安全作为适应度惩罚

传统 AI 安全方案是"拦截至输出层"——检测到危险内容就拦截。M-Engine 的做法是**直接修改收益函数**：

$$\text{收益}[i] = \text{重构贡献} - \text{安全风险}$$

安全风险高的基函数（如策略过于极端、能量过度集中、陷入认知闭环）获得惩罚，在复制者动态中自然被压制——不需要一个独立的"安全模块"去拦截。三个检测器持续运行：

- 频谱失真检测**：追踪每个事实的频谱历史，检测异常突变
- 偏好共振检测**：当用户和模型在某个维度上增益都极高时发出警报
- 认知闭环检测**：相同问答模式重复出现时警告

完整交互循环

将所有层次串联起来的单次交互：

用户："小明为什么哭了？"

↓

▼

[嵌入器] → 查询向量（768维）



统一方程

所有上述行为的数学来源可以压缩为一个**复制者-变方程**:

$$\dot{x}_i = x_i(\pi_i - \pi) + \sum_j (x_j Q_{ji} - x_i Q_{ij}) + \mu \cdot \text{Mutation}(x_i)$$

项	含义	对应行为
$x_i(\pi_i - \pi)$	收益高于均值的策略增殖	反馈学习、频谱更新
$\sum (x_j Q_{ji} - x_i Q_{ij})$	策略模仿与转换	基函数合并、偏好迁移
$\mu \cdot \text{Mutation}(x_i)$	随机创新	基函数新生、策略变异

而收益 π_i 本身是多目标复合:

$$\pi_i = \alpha \cdot \text{重构贡献} + \beta \cdot \text{探索价值} - \gamma \cdot \text{安全风险} - \delta \cdot \text{代谢消耗}$$

路由、偏好、学习、演化、安全、好奇——所有这些传统上需要独立模块的行为，都是这同一个方程在不同条件下的投影。

价值论证

1. 可解释性

每次回答后可以用 `show spectrum` 看到频谱分布、用 `show dynamics` 看到博弈种群状态、用 `show neural` 看到符号与神经的双空间对比。系统的"思考过程"完全透明。

2. 多视角理解

同一份记忆，不同问题/偏好得到不同回答。这不是 prompt engineering 层面的切换，而是频谱数据结构本身支持的多维激活。

3. 反馈即学习

不需要重新索引、不需要微调模型。一次反馈，频谱即时更新，下次生效。

4. 自演化知识结构

认知维度不是静态的。系统运行中会自动合并冗余维度、分裂过宽维度、淘汰无用维度、从数据中新生维度。

5. 跨记忆类比

所有事实在同一基函数空间中表示为频谱向量，天然支持余弦相似度计算。系统能自动发现"失业"和"分手"在【失去】【自我重估】等维度上的结构相似性。

6. AI 架构新范式

证明了一个原则：不要设计行为，设计适应度函数。6 个独立模块的行为可以从一个方程中涌现，消除了传统 AI 系统的"缝合感"。

与现有系统的区别

	RAG	Mem0	LangChain	M-Engine
存储形式	文本块+向量	结构化事实	文本块+向量	基函数频谱
检索方式	向量相似度	关键词/向量	向量相似度	频谱+嵌入双通道
多视角	靠prompt指令	不支持	靠prompt指令	频谱+滤波权重的数学结构
可解释性	无	低	无	每一步可审计
学习方式	重新索引	覆盖写入	重新索引	复制者动态增量更新
知识演化	不支持	不支持	不支持	基函数种群博弈演化
安全性	拦截层	无	无	适应度惩罚注入
LLM 依赖	强（生成回答）	强	强	仅文本合成，认知计算独立

局限性

这是学术原型，不是生产系统。

不能做的事

- **不能替代通用聊天机器人。**没有对话管理、没有上下文窗口、没有多轮意图理解。
- **不能做知识图谱级别的实体关系抽取。**基函数是抽象维度，不是具体的实体-关系-实体三元组。
- **不能在无基函数的世界中运作。**基函数库决定了认知天花板。面对完全超出当前基函数库范围的现象，系统要么视而不见，要么强行扭曲。
- **不能保证绝对真实性。**重构是生成式的，可能"脑补"出统计合理但事实错误的内容。
- **不能还原细节。**频谱是有损压缩，系统的"记忆"是骨架而非血肉。

技术债务

- 双空间神经调制仅在 DeepSeek API 下验证 (logprobs 可用)，其他 API 自动降级
- 嵌入目前使用 DeepSeek hash fallback 或本地 Ollama，未接入商业嵌入 API
- 无分布式部署、无并发支持、无访问控制
- 演化触发节奏（冷却时间、触发间隔）未经大规模实验调优

适用场景的诚实边界

它适合做：个人记忆助手（日记分析、长期偏好追踪）、研究原型（认知架构实验）、可解释 AI 的参考实现。

它不适合做：企业级知识库、客服机器人、任何需要 100% 准确率的场景。